



DATA FLOW 2025

MASTERING THE DATA WAVES

Insights Flow

Đinh An Khánh
Hoàng Việt Hưng
Bùi Quang Vinh
An Đức Trung

MỤC LỤC

I. Overview	3
1. Giới thiệu	3
2. Bối cảnh kinh doanh	3
2.1. Thực Trạng Hiện Tại	3
2.2. Hệ Quả Kinh Doanh	3
3. Mục tiêu của hệ thống đề xuất	3
3.1. Cá nhân hóa trải nghiệm khách hàng	3
3.2. Gia tăng doanh thu và tối ưu hiệu quả kinh doanh	3
3.3. Nâng cao vị thế cạnh tranh của ngân hàng	4
4. Giải Pháp Đề Xuất	4
4.1. Phân tích dữ liệu 2016	4
4.2. Xây dựng mô hình học máy dự đoán sản phẩm	4
5. Lợi ích và tác động đến doanh nghiệp	5
II. Exploratory Data Analysis	6
1. Check missing values and Dropping unnecessary columns	6
1.1. Thông tin cơ bản các trường dữ liệu	6
1.2. Xử lý dữ liệu bị thiếu và dữ liệu bị trùng lặp	7
2. Distribution & correlation between input variables and customers analysis	9
2.1. Phân phối các trường dữ liệu	9
2.2. Phân phối theo Tổng số sản phẩm	13
3. Hệ số tương quan	17
4. Phân bố dữ liệu	18
4.1. Phân bố dữ liệu theo độ tuổi	18
4.2. Phân bố dữ liệu theo thu nhập hộ gia đình	19
III. Data Preprocessing	20
1. Mã hóa	20
2. Định nghĩa các hàm xử lý.	22
3. Tiền xử lý dữ liệu.	25
4. Mô tả các biến sử dụng trong mô hình	30
IV. Model Training and Evaluation	31
1. Lựa chọn mô hình - XGBoost	31
2. Tham số mô hình	31
3. Dự đoán	33
4. Đánh giá	33

4.1. Mean Average Precision (MAP)	34
4.2. Precision	35
4.3. Recall	35
4.4. Kết quả đánh giá	36
V. Tối ưu code	38
1. Tối ưu hóa bằng hàm (def)	38
2. Tải xuống dataset đã được chuẩn hóa và làm sạch	38
3. Dùng csv.DictReader để đọc từng dòng, tiết kiệm RAM	38
VI. CONCLUSION & RECOMMENDATIONS:	39
1. Conclusion	39
1.1. EDA	39
1.2. Mô hình dự đoán	40
2. Recommendations:	41

I. Overview

1. Giới thiệu

Ngân hàng bán lẻ và tài chính cá nhân đang tìm kiếm cách tối ưu hóa việc giới thiệu sản phẩm cho khách hàng. Hiện tại, hệ thống đề xuất còn nhiều hạn chế, dẫn đến trải nghiệm khách hàng không đồng nhất. Mục tiêu của bài toán là xây dựng một hệ thống đề xuất thông minh, cá nhân hóa để tăng mức độ gắn kết và tối đa hóa hiệu quả kinh doanh.

2. Bối cảnh kinh doanh

2.1. Thực Trạng Hiện Tại

- Ngân hàng cung cấp nhiều sản phẩm tài chính như tài khoản tiết kiệm, thẻ tín dụng, khoản vay, bảo hiểm, đầu tư...
- Hệ thống đề xuất sản phẩm hiện tại chưa tối ưu:
 - Một số khách hàng nhận quá nhiều gợi ý, gây khó chịu.
 - Nhiều khách hàng khác không nhận được bất kỳ đề xuất nào, làm giảm cơ hội tiếp cận sản phẩm phù hợp.
- Kết quả: Giảm mức độ hài lòng, giảm gắn kết khách hàng và bỏ lỡ cơ hội tăng doanh thu.

2.2. Hệ Quả Kinh Doanh

- Mất cơ hội bán chéo & bán thêm: Ngân hàng không tận dụng được dữ liệu để giới thiệu sản phẩm phù hợp.
- Trải nghiệm khách hàng không đồng đều: Một số khách hàng nhận quá nhiều thông tin, số khác không nhận đủ.
- Sự trung thành khách hàng giảm sút: Khách hàng không cảm thấy được quan tâm đúng mức.

3. Mục tiêu của hệ thống đề xuất

3.1. Cá nhân hóa trải nghiệm khách hàng

- Hiểu rõ nhu cầu của từng khách hàng để gợi ý sản phẩm chính xác hơn.
- Đảm bảo mọi khách hàng đều nhận được những sản phẩm phù hợp.

3.2. Gia tăng doanh thu và tối ưu hiệu quả kinh doanh

- Tận dụng dữ liệu khách hàng để xác định nhu cầu tiềm ẩn.
- Tăng tỷ lệ bán chéo (cross-selling) và bán thêm (up-selling).
- Giảm lãng phí chi phí marketing bằng cách nhắm đúng khách hàng, đúng sản phẩm.

3.3. Nâng cao vị thế cạnh tranh của ngân hàng

- Hệ thống đề xuất thông minh giúp ngân hàng dẫn đầu trong dịch vụ tài chính cá nhân.
- Tạo ra một trải nghiệm liền mạch và tiện lợi, giúp khách hàng gắn bó lâu dài.

4. Giải Pháp Đề Xuất

4.1. Phân tích dữ liệu 2016

- Thu thập và xử lý dữ liệu khách hàng: Làm sạch, chuẩn hóa và khai phá dữ liệu hành vi tài chính.
 - Từ đó xác định được đối tượng khách hàng của ngân hàng cũng như hành vi sử dụng sản phẩm của họ.
 - Bên cạnh đó, việc xử lý còn giúp đảm bảo chất lượng dữ liệu cho các công đoạn phía sau
- Tạo đặc trưng (Feature Engineering): Xây dựng các biến số quan trọng giúp mô hình hiểu rõ khách hàng hơn.
- Huấn luyện mô hình:
 - Kết hợp các phương pháp Machine Learning (ML), Collaborative Filtering.
 - Dùng chỉ số Mean Average Precision (MAP) để đánh giá độ chính xác.

4.2. Xây dựng mô hình học máy dự đoán sản phẩm

- 1. Khám phá và làm sạch dữ liệu**
 - Loại bỏ dữ liệu thiếu, không nhất quán.
 - Phân tích xu hướng sử dụng sản phẩm của khách hàng.
- 2. Khai thác đặc trưng quan trọng**
 - Xác định yếu tố ảnh hưởng đến hành vi mua hàng.
 - Chọn ra các biến có tác động lớn đến mô hình dự đoán.
- 3. Xây dựng và tối ưu mô hình dự đoán**
 - Thử nghiệm nhiều thuật toán khác nhau.
 - Tối ưu hóa tốc độ xử lý để đảm bảo hiệu suất.

4. Dự đoán danh sách sản phẩm phù hợp cho từng khách hàng

- Gợi ý các sản phẩm khách hàng có khả năng mua cao nhất.

5. Lợi ích và tác động đến doanh nghiệp

- Tăng mức độ hài lòng của khách hàng

- Đề xuất sản phẩm phù hợp với nhu cầu và thời điểm thích hợp.
- Gia tăng trải nghiệm cá nhân hóa, giúp khách hàng dễ dàng tiếp cận sản phẩm quan tâm.

- Gia tăng doanh thu và tối ưu hóa chi phí

- Tăng tỷ lệ chuyển đổi (conversion rate) thông qua bán chéo và bán thêm hiệu quả.
- Tối ưu hóa chi phí marketing bằng cách nhắm đúng đối tượng, giảm lãng phí tài nguyên và hạn chế quảng cáo không cần thiết.

- Cải thiện chiến lược kinh doanh và quản trị rủi ro

- Nâng cao hiệu quả các chiến dịch marketing, tập trung vào nhóm khách hàng tiềm năng.
- Dự đoán xu hướng tài chính của khách hàng, giúp ngân hàng điều chỉnh chiến lược kịp thời.

- Tạo lợi thế cạnh tranh mạnh mẽ

- Cung cấp dịch vụ cá nhân hóa tốt hơn so với đối thủ.
- Đảm bảo khách hàng tiềm năng được tiếp cận các sản phẩm phù hợp, từ đó nâng cao lòng trung thành và giá trị vòng đời khách hàng.

II. Exploratory Data Analysis

Phân tích dữ liệu khám phá (Exploratory Data Analysis - EDA) là quá trình phân tích và tóm tắt tập dữ liệu nhằm khám phá các mẫu, mối quan hệ và thông tin chi tiết, thường được thực hiện như một bước đầu tiên trước khi xây dựng mô hình dự đoán hoặc thực hiện các kiểm định thống kê.

1. Check missing values and Dropping unnecessary columns

1.1. Thông tin cơ bản các trường dữ liệu

	dtype	instances	unique
fecha_dato	object	4621976	5
ncodpers	int64	4621976	938423
ind_empleado	object	4621976	5
pais_residencia	object	4621976	118
sexo	object	4621951	2
age	int64	4621976	119
fecha_alta	object	4621976	6751
ind_nuevo	float64	4621976	2
antiguedad	int64	4621976	258
indrel	float64	4621976	2
ult_fec_cli_1t	object	8683	100
indrel_1mes	object	4597744	13
tiprel_1mes	object	4597744	5
indresi	object	4621976	2
indext	object	4621976	2
conyuemp	object	579	2
canal_entrada	object	4583151	162
indfall	object	4621976	2
tipodom	float64	4621976	1
cod_prov	float64	4602042	52
nomprov	object	4602042	52
ind_actividad_cliente	float64	4621976	2
renta	float64	3519074	518614
segmento	object	4581617	3
...			
ind_viv_fin_ult1	int64	4621976	2
ind_nomina_ult1	float64	4621976	2
ind_nom_pens_ult1	float64	4621976	2
ind_recibo_ult1	int64	4621976	2

Bộ dữ liệu bao gồm 48 biến, trong đó:

- **Biến dạng số (Numerical - 3 biến):** age, antigüedad, renta

- **Biến phân loại (Categorical - 14 biến):** ind_empleado, pais_residencia, indrel, indrel_1mes, tiprel_1mes, canal_entrada, cod_prov, nomprov, segmento, sexo, indresi, indext, indfall, tipodom
- **Biến nhị phân (Binary variables - 31 biến):** Các biến còn lại như: nd_nuevo, conyuemp, ind_actividad_cliente...

1.2. Xử lý xử liệu bị thiếu và dữ liệu bị trùng lặp

```
Số lượng giá trị bị thiếu:
conyuemp          4621397
ult_fec_cli_1t    4613293
renta             1102902
segmento          40359
canal_entrada     38825
indrel_1mes       24232
tiprel_1mes       24232
cod_prov          19934
nomprov           19934
sexo              25
age               0
fecha_alta        0
ind_nuevo         0
fecha_dato        0
ind_empleado      0
ncodpers          0
indext            0
indresi           0
indrel            0
antiguedad        0
pais_residencia   0
indfall           0
tipodom           0
ind_actividad_cliente 0
...
ind_nomina_ult1   0
ind_nom_pens_ult1 0
ind_recibo_ult1   0
dtype: int64
```


- Cột “conyuemp” là Chỉ số vợ/chồng: 1 nếu khách hàng là vợ/chồng của nhân viên. Cột này bị null tới 99.9% và không có quá nhiều ý nghĩa trong việc phân tích vậy nên nhóm chúng tôi đề xuất loại bỏ(drop)

- Cột “ult_fec_cli_1t” là Ngày cuối cùng là khách hàng chính (nếu không phải cuối tháng). Tương tự như cột “conyuemp”, nhóm chúng tôi đề xuất loại bỏ(drop)
- Cột “renta” là Thu nhập hộ gia đình trước thuế, nhóm chúng tôi chia dữ liệu theo từng nhóm khu vực “nomprov” để fill null
- Cột “segmento” là Phân khúc: 01 - VIP, 02 - Cá nhân, 03 - Tốt nghiệp đại học. Chúng tôi nhóm dữ liệu theo salary và tìm giá trị phổ biến nhất (mode) của customer_segment
- Cột “canal_entrada” là Kênh khách hàng sử dụng để gia nhập. Chúng tôi điền “UNKNOWN” vào những giá trị bị thiếu
- Cột “indrel_1mes” là Loại khách hàng đầu tháng: 1 (Khách hàng chính), 2 (Đồng sở hữu), P (Tiềm năng), 3 (Khách hàng chính cũ), 4 (Đồng sở hữu cũ). Chúng tôi điền “P” vào những giá trị thiếu
- Cột “tiprel_1mes” là Loại quan hệ khách hàng đầu tháng: A (Hoạt động), I (Không hoạt động), P (Khách hàng cũ), R (Tiềm năng). Chúng tôi điền “A” vào những giá trị thiếu
- Cột “cod_prov” và “nomprov” là Mã tỉnh và Tên tỉnh. Nhóm chúng tôi sẽ drop vì không có quá nhiều ý nghĩa phân tích
- Cột ‘sexo’ là giới tính của khách hàng, chúng tôi fill null với giá trị mode (xuất hiện nhiều nhất)

2. Distribution & correlation between input variables and customers analysis


2.1. Phân phối các trường dữ liệu

Khách hàng của ngân hàng chủ yếu là người bên ngoài, không phải nội bộ.




- 99% khách hàng không phải nhân viên ngân hàng.
- 1% còn lại phân bổ cho những nhân viên đang làm hoặc đã nghỉ việc.

Khách hàng của ngân hàng chủ yếu là người Tây Ban Nha




- Số lượng khách hàng có quốc gia cư trú là Tây Ban Nha (ES) vượt trội với 4.620.238 người
- Các quốc gia khác như Pháp (FR), Argentina (AR), Anh (GB), Đức (DE), Mỹ (US), và các nước khác có số lượng khách hàng thấp hơn rất nhiều

Khách hàng chủ yếu là những người trong độ tuổi lao động, tập trung chính vào giai đoạn 23-25 và 40-45 tuổi




- Phân bố không đồng đều, tập trung vào độ tuổi trẻ: Phần lớn khách hàng rơi vào khoảng 20-40 tuổi, với đỉnh cao nhất ở khoảng 23-25 tuổi.
- Sự sụt giảm dần theo tuổi: Số lượng khách hàng giảm dần khi tuổi tăng, với rất ít khách hàng trên 80 tuổi, và một số giá trị ngoại lệ cao hơn 100 tuổi.

Khách hàng phân chia đồng đều ở cả 2 giới, tuy nhiên giới nữ nhỉnh hơn 1 chút




- Chênh lệch giới tính: Số lượng khách hàng nữ (V) là 2.507.310, cao hơn so với khách hàng nam (H) với 2.114.641.
- Tỷ lệ không quá chênh lệch: Mặc dù nữ chiếm số lượng cao hơn, nhưng sự chênh lệch không quá lớn, cho thấy sự cân bằng tương đối về giới tính trong tập khách hàng.

Khách hàng đa phần gắn bó dưới 4 năm với công ty




- Phân bố khách hàng theo thâm niên không đồng đều: Số lượng khách hàng cao nhất tập trung ở mức thâm niên thấp (dưới 50 tháng), sau đó giảm dần khi thâm niên tăng.
- Có một số điểm tăng bất thường: Có một cụm khách hàng với thâm niên khoảng 150 tháng có tần suất cao hơn bình thường, cho thấy khả năng có nhóm khách hàng lâu năm đặc biệt.

Khách hàng chủ yếu bắt đầu với trạng thái “Khách hàng chính”. Đây là nhóm khách hàng mang lại doanh thu ổn định và có giá trị cao đối với ngân hàng.




- Khách hàng chính chiếm đa số: Loại khách hàng 1.0 (Khách hàng chính) có số lượng vượt trội 4.614.058, chiếm phần lớn trong tập dữ liệu.
- Các nhóm khác rất ít: Các loại khách hàng khác như đồng sở hữu (2.0), tiềm năng (P), khách hàng chính cũ (3.0), đồng sở hữu cũ (4.0) có số lượng rất nhỏ, với nhóm lớn nhất

Khách hàng nằm chủ yếu trong ba kênh lớn nhất



- KHE (1.26 triệu), KAT (1.03 triệu), KFC (1.00 triệu) → Đây là ba kênh thu hút khách hàng nhiều nhất, chiếm phần lớn lượng khách hàng mới.
- Điều này cho thấy các kênh này đang hoạt động hiệu quả và có thể là trọng tâm trong chiến lược thu hút khách hàng. Sự chênh lệch giữa các kênh cũng vô cùng lớn

Khách hàng của công ty tập trung chính ở các thành phố lớn




- Madrid có số lượng khách hàng cao nhất với 1.48 triệu (32%), gấp hơn 3 lần so với Barcelona (440K). Điều này có thể do dân số đông, kinh tế phát triển hoặc nhiều chi nhánh ngân hàng.
- Barcelona (440K) và Valencia (238K) đứng thứ hai và ba, phù hợp với vai trò là trung tâm kinh tế lớn.
- Các tỉnh còn lại có lượng khách hàng giảm dần nhưng vẫn đáng kể, gồm Sevilla (201K), Coruña (143K), Murcia (137K), Malaga (121K), Zaragoza (115K), Alicante (109K), Cadiz (98K).

2.2. Phân phối theo Tổng số sản phẩm

- Phân phối theo giới tính và chỉ số hoạt động

Khách hàng nam giới ưu tiên sử dụng tài khoản điện tử và ghi nợ tự động, trong khi nữ giới có xu hướng lập kế hoạch tài chính dài hạn hơn với lương hưu.




- Nhóm khách hàng nam (H)
 - H, 1.0 (nam hoạt động) sử dụng tài khoản điện tử, tài khoản hiện tại, và ghi nợ tự động nhiều hơn so với các sản phẩm khác.
 - H, 0.0 (nam không hoạt động) vẫn chiếm tỷ lệ lớn trong tài khoản hiện tại nhưng ít sử dụng các sản phẩm tài chính khác.
- Nhóm khách hàng nữ (V)
 - V, 1.0 (nữ hoạt động) có mức sử dụng tài khoản hiện tại cao nhất trong tất cả nhóm. Họ cũng sử dụng ghi nợ tự động, tài khoản điện tử và lương hưu (pension_salary) nhiều hơn nam giới.
 - V, 0.0 (nữ không hoạt động) cũng có tài khoản hiện tại nhưng ít tham gia vào các sản phẩm khác.

- Phân phối theo thu nhập

Khách hàng **thu nhập thấp** chủ yếu sử dụng tài khoản hiện tại và ghi nợ tự động, ít tham gia đầu tư hay bảo hiểm;

Khách hàng **thu nhập trung bình** bắt đầu sử dụng tín dụng, đầu tư và tài khoản số hóa.


Khách hàng **thu nhập cao** tham gia mạnh vào mọi sản phẩm tài chính, đặc biệt là đầu tư, tín dụng và bảo vệ tài sản dài hạn.



- Nhóm thu nhập thấp (0 - 50,000)
 - Chủ yếu sử dụng current accounts và direct debit
 - Sử dụng e_account ở mức vừa phải, cho thấy một số lượng nhất định khách hàng có xu hướng giao dịch online.
 - Rất ít tham gia vào đầu tư, bảo hiểm và thế chấp
- Nhóm thu nhập trung bình (50,000 - 100,000 & 100,000 - 200,000)
 - Tăng dần mức độ tham gia vào các sản phẩm tín dụng và đầu tư như quỹ đầu tư, bảo hiểm, và tài khoản tiết kiệm.
 - Sử dụng mạnh các dịch vụ ghi nợ tự động và tài khoản online
- Nhóm thu nhập cao (>200,000)
 - Tham gia nhiều nhất vào tất cả các sản phẩm tài chính, đặc biệt là đầu tư, tín dụng và tài khoản điện tử.
 - Khoản vay (loans), thế chấp (mortgage) và bảo hiểm hưu trí (pension_salary) được sử dụng nhiều hơn so với các nhóm thu nhập thấp hơn.
 - Nhóm này có xu hướng sử dụng các dịch vụ tài chính phức tạp hơn, có thể liên quan đến việc đầu tư và bảo vệ tài sản dài hạn.

- Phân phối theo độ tuổi


Khách hàng chủ yếu sử dụng tài khoản hiện tại và tài khoản tiết kiệm, phản ánh nhu cầu tài chính cơ bản, trong đó nhóm tuổi 40-80 có mức độ sử dụng sản phẩm ngân hàng cao nhất, là đối tượng khách hàng trọng tâm, trong khi các sản phẩm đầu tư ít được quan tâm, cần chiến lược thu hút nhóm khách hàng trung và cao cấp để thúc đẩy phân khúc này.



- Current account và saving accounts chiếm ưu thế → Hai sản phẩm này có lượng sử dụng cao nhất, phản ánh nhu cầu tài chính cơ bản của khách hàng.
- Nhóm tuổi 40-60 và 60-80 sử dụng nhiều sản phẩm nhất → Đây là nhóm khách hàng chính, có nhu cầu tài chính cao nhất, tập trung vào các sản phẩm thanh toán và tiết kiệm.
- Các sản phẩm đầu tư (securities, investment funds) ít được sử dụng → Cần có chiến lược thúc đẩy để thu hút nhóm khách hàng trung và cao cấp

- Phân phối theo thâm niên


Khách hàng có xu hướng sử dụng sản phẩm tỉ lệ thuận với thâm niên gắn bó với ngân hàng



- Mỗi quan hệ thuận giữa số lượng sản phẩm và thâm niên: Khách hàng có số lượng sản phẩm cao hơn thường có thâm niên cao hơn trong ngân hàng.
- Sự gia tăng đều đặn: Trung bình, thâm niên khách hàng tăng dần khi số lượng sản phẩm sử dụng tăng, cho thấy khách hàng lâu năm có xu hướng sở hữu nhiều sản phẩm hơn.

- Phân phối theo tháng


Khách hàng trong 2016 mua nhiều sản phẩm vào tháng 2, cho thấy đây là thời điểm có những những chiến lược tiếp thị khá thành công



Tốc độ tăng trưởng không ổn định: Mặc dù tổng số sản phẩm tăng đều mỗi tháng, nhưng mức tăng có sự biến động. Tháng 02/2016 có mức tăng mạnh nhất (+16.684 sản phẩm), nhưng những tháng sau đó tăng chậm lại.

Dấu hiệu chứng lại cần lưu ý: Sau khi giảm mức tăng từ tháng 02 đến 04, tháng 05 có sự phục hồi nhẹ với +6.642 sản phẩm, cho thấy ngân hàng có thể cần đẩy mạnh các chiến dịch thu hút khách hàng để duy trì tăng trưởng.


3. Hệ số tương quan



- Customer_activity_index và Total có mối tương quan dương mạnh với hệ số 0.57, cho thấy sự liên kết chặt chẽ giữa hai biến.
- Age và Total có mối tương quan dương nhẹ với hệ số 0.16.
- Age và customer_activity_index có mối tương quan dương nhỏ với hệ số 0.12.
- New_customer_index và Age có mối tương quan âm với hệ số -0.15.
- New_customer_index và Total có mối tương quan âm nhẹ với hệ số -0.09.


4. Phân bố dữ liệu

4.1. Phân bố dữ liệu theo độ tuổi



- Phân bố dữ liệu:
 - Khoảng giá trị chính: Phần lớn dữ liệu tuổi nằm trong khoảng từ khoảng 20 đến 50 tuổi, đây là phạm vi chứa phần lớn giá trị.
 - Median (đường ngang trong hộp): Giá trị trung vị (median) của tuổi rơi vào khoảng 30-40 tuổi
- Outliers (Giá trị ngoại lai):
 - Có một số điểm dữ liệu nằm cao hơn 100 tuổi, đặc biệt có giá trị lớn hơn 160 tuổi, đây là các outlier (dấu chấm phía trên).
 - Những outliers này có thể là do dữ liệu bị lỗi, giá trị nhập sai, hoặc có một số ít cá nhân thực sự có tuổi cao bất thường trong dataset.
- Phạm vi dữ liệu:
 - Min (giá trị thấp nhất, không tính outlier): Khoảng dưới 5 tuổi.
 - Max (giá trị cao nhất, không tính outlier): Khoảng 90-100 tuổi.

4.2. Phân bố dữ liệu theo thu nhập hộ gia đình



- Có rất nhiều giá trị outliers (các điểm tròn phía trên) kéo dài đến gần 30 triệu.
- Những giá trị này có thể là thu nhập cực cao của một số ít hộ gia đình hoặc có khả năng là dữ liệu nhập sai.
- Sự tồn tại của nhiều outliers làm cho phần hộp (IQR - Interquartile Range) gần như bị ép sát xuống đáy, khó quan sát được phân bố thực sự của phần lớn dữ liệu.

III. Data Preprocessing

1. Mã hóa

Đầu tiên, nhóm tạo một **từ điển ánh xạ (dictionary)** để chuyển các giá trị danh mục (categorical) thành **số nguyên**. Các mô hình học máy yêu cầu dữ liệu đầu vào ở dạng số, thay vì dạng chuỗi. Chi tiết về từ điển ánh xạ được giải thích như sau:

```
import csv
import datetime
import numpy as np
import pandas as pd
import xgboost as xgb

categories_dict = {'ind_empleado' : {'MISS':0, 'N':1, 'B':2, 'F':3, 'A':4, 'S':5},
'sexo' : {'V':0, 'H':1, 'MISS':2},
'ind_nuevo' : {'0':0, '1':1, 'MISS':1},
'indrel' : {'1':0, '99':1, 'MISS':1},
'indrel_1mes' : {'MISS':0, '1.0':1, '1':1, '2.0':2, '2':2, '3.0':3, '3':3, '4.0':4, '4':4, 'P':5},
'tiprel_1mes' : {'MISS':0, 'I':1, 'A':2, 'P':3, 'R':4, 'N':5},
'indresi' : {'MISS':0, 'S':1, 'N':2},
'indext' : {'MISS':0, 'S':1, 'N':2},
'indfall' : {'MISS':0, 'S':1, 'N':2},
'tipodom' : {'MISS':0, '1':1},
'ind_actividad_cliente' : {'0':0, '1':1, 'MISS':2},
'segmento' : {'02 - PARTICULARES':0, '03 - UNIVERSITARIO':1, '01 - TOP':2, 'MISS':3},
```

- **ind_empleado:** Tình trạng nhân viên (Nghĩa là khách hàng có phải nhân viên của ngân hàng hay không).
 - 'MISS' (thiếu dữ liệu) được gán là 0.
 - 'N' (Không phải nhân viên) là 1.
 - 'B', 'F', 'A', 'S' là các mã khác nhau, lần lượt được gán 2, 3, 4, 5.
- **sexo:** Giới tính khách hàng.
 - 'V' (Nữ) được gán giá trị 0;
 - 'H' (Nam) được gán giá trị 1;
 - 'MISS' (thiếu dữ liệu) được gán giá trị 2.
- Tương tự cho các biến danh mục khác như **ind_nuevo**, **indrel**, **indrel_1mes**.
- **pais_residencia:** Quốc gia nơi khách hàng cư trú. Mỗi mã quốc gia (ví dụ: 'LV' cho Latvia, 'BE' cho Bỉ, 'FR' cho Pháp, v.v.) được gán một số nguyên duy nhất.
- **canal_entrada:** Kênh mà khách hàng sử dụng để tiếp cận dịch vụ ngân hàng. Mỗi giá trị như 'KHE', 'KHD', 'KHF' cũng được gán một mã số.

Dòng lệnh này lấy tất cả tên các biến danh mục đã được định nghĩa trong `categories_dict`.

Sau đó, ta có thể dễ dàng lặp qua `category_features` để chuyển dữ liệu từ dạng chuỗi sang dạng số trong quá trình tiền xử lý (ví dụ, sử dụng vòng lặp `for col in category_features`).

Tiếp theo, nhóm tạo danh sách các sản phẩm ngân hàng. Sau đó, loại bỏ 2 sản phẩm đầu tiên, do các sản phẩm này không được sử dụng bởi nhiều khách hàng so với các sản phẩm còn lại.

```
products = ['ind_ahor_fin_ult1', 'ind_aval_fin_ult1', 'ind_cco_fin_ult1', 'ind_cder_fin_ult1', 'ind_cno_fin_ult1', 'ind_ctju_fin_ult1',  
            'ind_ctma_fin_ult1', 'ind_ctop_fin_ult1', 'ind_ctpp_fin_ult1', 'ind_deco_fin_ult1', 'ind_deme_fin_ult1', 'ind_dela_fin_ult1',  
            'ind_ecue_fin_ult1', 'ind_fond_fin_ult1', 'ind_hip_fin_ult1', 'ind_plan_fin_ult1', 'ind_pres_fin_ult1', 'ind_reca_fin_ult1',  
            'ind_tjcr_fin_ult1', 'ind_valo_fin_ult1', 'ind_viv_fin_ult1', 'ind_nomina_ult1', 'ind_nom_pens_ult1', 'ind_recibo_ult1']  
products = products[2:]
```

2. Định nghĩa các hàm xử lý.

- **Hàm `process_products(row)`** chuyển đổi danh sách các sản phẩm ngân hàng từ dữ liệu gốc (row) thành danh sách nhị phân (0 hoặc 1), từ đó xác định khách hàng có sử dụng sản phẩm đó hay không.
 - Nếu giá trị bị thiếu (" hoặc 'NA'), mặc định là 0 (tức không sở hữu sản phẩm).
 - Nếu có giá trị hợp lệ, chuyển đổi thành số nguyên.

```
def Process_products(row):  
    tlist = []  
    for col in products:  
        if row[col].strip() in ['', 'NA']:  
            target = 0  
        else:  
            target = int(float(row[col]))  
        tlist.append(target)  
    return tlist
```

- **Hàm `Process_index(row, col)`** chuyển đổi các biến danh mục (categorical variables) thành số nguyên, giúp mô hình hiểu các đặc trưng không phải là số.
 - Loại bỏ khoảng trắng trong dữ liệu (strip()).
 - Nếu giá trị hợp lệ, chuyển sang số từ `categories_dict`.
 - Nếu giá trị bị thiếu (" hoặc 'NA'), thay bằng giá trị 'MISS' trong `categories_dict`.
 - Các giá trị thiếu sẽ được mã hóa dựa trên từng đặc trưng trong `categories_dict`.

```
def Process_Index(row, col):  
    val = row[col].strip()  
    if val not in ['', 'NA']:  
        ind = categories_dict[col][val]  
    else:  
        ind = categories_dict[col]['MISS']  
    return ind
```

- **Hàm Process_Age(row)** đảm bảo giá trị hợp lệ và chuẩn hóa về khoảng [0,1]. Để thực hiện hàm này, nhóm đã thực hiện các bước như sau:

```
def Process_Age(row):
    mean_age = 40.
    min_age = 18.
    max_age = 100.
    range_age = max_age - min_age
    age = row['age'].strip()
    if age == 'NA' or age == '':
        age = mean_age
    else:
        age = float(age)
        if age < min_age:
            age = min_age
        elif age > max_age:
            age = max_age
    return round( (age - min_age) / range_age, 4)
```

- **Thiết lập giá trị:** Tuổi trung bình: **40**; Giới hạn tuổi: **18 đến 100**.
- **Xử lý giá trị thiếu:** Nếu dữ liệu bị thiếu ("NA" hoặc ""), thay thế bằng **40**.
- **Giới hạn tuổi hợp lệ:** Nếu tuổi < **18**, gán bằng **18**; Nếu tuổi > **100**, gán bằng **100**.
- **Chuẩn hóa Min-Max Scaling:** Đưa kết quả nằm trong khoảng **[0,1]**.

$$\text{normalized_age} = \frac{\text{age} - \text{min_age}}{\text{range_age}}$$

- Tương tự, hàm **Process_Seniority(row)** thực hiện việc chuẩn hóa dữ liệu về khoảng [0,1]


```
def Process_Seniority(row):
    min_value = 0.
    max_value = 256.
    range_value = max_value - min_value
    missing_value = 0.
    cust_seniority = row['antiguedad'].strip()
    if cust_seniority == 'NA' or cust_seniority == '':
        cust_seniority = missing_value
    else:
        cust_seniority = float(cust_seniority)
        if cust_seniority < min_value:
            cust_seniority = min_value
        elif cust_seniority > max_value:
            cust_seniority = max_value
    return round((cust_seniority-min_value) / range_value, 4)
```

- **Thiết lập giá trị giới hạn:** Giá trị tối thiểu (min_value): **0**; Giá trị tối đa (max_value): **256**.
- **Xử lý giá trị thiếu:** Nếu dữ liệu bị thiếu ("NA" hoặc ""), thay thế bằng **0**.
- **Giới hạn giá trị hợp lệ:** Nếu thâm niên < **0**, gán bằng **0**; Nếu thâm niên > **256**, gán bằng **256**.
- Chuẩn hóa Min-Max Scaling:

$$\text{normalized_seniority} = \frac{\text{cust_seniority} - \text{min_value}}{\text{range_value}}$$

- **Hàm Process_Renta(row)** chuẩn hóa thu nhập của khách hàng về khoảng [0,1] bằng Min-Max Scaling.

```
def Process_Renta(row):
    min_value = 0.
    max_value = 1500000.
    range_value = max_value - min_value
    rent = row['renta'].strip()
    if rent == 'NA' or rent == '':
        if row['nomprov'] == 'NA' or row['nomprov'] == '':
            rent = float(renta_dict['UNKNOWN'])
        else:
            rent = float(renta_dict[row['nomprov']])
    else:
        rent = float(rent)
        if rent < min_value:
            rent = min_value
        elif rent > max_value:
            rent = max_value

    return round((rent-min_value) / range_value, 6)
```

- **Xử lý giá trị thiếu:** Nếu thu nhập bị thiếu ("NA" hoặc ""), thay thế bằng **thu nhập trung bình của tỉnh** (nomprov); Nếu thông tin tỉnh cũng bị thiếu, thay thế bằng **giá trị mặc định** từ renta_dict['UNKNOWN'].
 - **Giới hạn phạm vi hợp lệ:** Nếu thu nhập < 0, gán bằng 0; Nếu thu nhập > 1.500.000, gán bằng 1.500.000.
 - **Chuẩn hóa Min-Max Scaling:** Đưa giá trị thu nhập về khoảng [0,1].
- **Hàm getMonth(row)** trích xuất tháng từ cột fecha_dato, trong đó dữ liệu ngày được lưu theo định dạng Y-M-D. Hàm này tách chuỗi theo dấu '-' và lấy phần tử thứ hai (tương ứng với tháng), sau đó chuyển đổi thành số nguyên.

```
def getMonth(row):
    return int(row['fecha_dato'].split('-')[1])
```

3. Tiền xử lý dữ liệu.

Hàm **DataPreprocessing()** thực hiện tiền xử lý dữ liệu khách hàng để chuẩn bị đầu vào cho mô hình học máy dự đoán sản phẩm ngân hàng mà khách hàng có thể mua trong tháng 5/2016.

```
def DataPreprocessing(in_file_name, cust_dict, lag_cust_dict1, lag_cust_dict2, lag_cust_dict3):
```

Tham số đầu vào: **in_file_name**: Tập chứa dữ liệu khách hàng theo từng tháng;
cust_dict: Từ điển lưu trữ trạng thái sản phẩm của khách hàng trong tháng trước;
lag_cust_dict1, lag_cust_dict2, lag_cust_dict3: Các từ điển lưu trữ trạng thái sản phẩm của khách hàng trong các tháng trước đó.

Các bước thực hiện trong hàm:

- **Khởi tạo danh sách đặc trưng và nhãn dự đoán:**

```
x_vars_list = []  
y_vars_list = []
```

- **x_vars_list**: Lưu trữ đặc trưng đầu vào cho mô hình.
- **y_vars_list**: Lưu trữ nhãn dự đoán (sản phẩm mới mà khách hàng đã mua).
- **Duyệt từng dòng dữ liệu trong file CSV:**
 - Bỏ qua các bản ghi không thuộc các mốc thời gian quan trọng (từ 2015-01 đến 2016-05).
- **Lưu trữ trạng thái sản phẩm theo từng tháng:**
 - Nếu ngày là **2015-01** hoặc **2016-01**, lưu trạng thái sản phẩm vào lag_cust_dict1.
 - Nếu ngày là **2015-02** hoặc **2016-02**, lưu vào lag_cust_dict2.
 - Nếu ngày là **2015-03** hoặc **2016-03**, lưu vào lag_cust_dict3.
 - Nếu ngày là **2015-04** hoặc **2016-04**, lưu vào cust_dict (trạng thái sản phẩm gần nhất trước tháng dự đoán).
- **Xử lý dữ liệu đặc trưng:**

```

x_vars = []
for col in category_features:
    x_vars.append( Process_Index(row, col) )
sex = Process_Index(row, 'sexo')
age = Process_Age(row)
x_vars.append(age)
x_vars.append( getMonth(row) )
x_vars.append(Process_Seniority(row))
income = Process_Renta(row)
x_vars.append(income)

```

- Chuyển đổi biến danh mục (category_features) sang số nguyên bằng hàm Process_Index().
- Xử lý tuổi khách hàng bằng hàm Process_Age().
- Trích xuất tháng từ cột fecha_dato bằng getMonth().
- Xử lý số tháng thâm niên (antigüedad) bằng Process_Seniority().
- Xử lý thu nhập (renta) bằng Process_Renta().

• Xử lý dữ liệu huấn luyện:

Đoạn mã này trích xuất và xử lý dữ liệu sản phẩm mà khách hàng đã sở hữu trong các tháng trước đó. Nó phục vụ cho quá trình huấn luyện mô hình bằng cách:

- **Tạo đặc trưng đầu vào (x_vars_list):** Gồm thông tin về khách hàng và trạng thái sản phẩm của họ trong các tháng trước.
- **Tạo nhãn đầu ra (y_vars_list):** Là danh sách sản phẩm mới mà khách hàng đã mua vào tháng 5/2015.

```

if row['fecha_dato'] == '2016-05-28':
    prev_target_list = cust_dict.get(cust_id, [0]*22)
    lag_target_list1 = lag_cust_dict1.get(cust_id, [0]*22)
    lag_target_list2 = lag_cust_dict2.get(cust_id, [0]*22)
    lag_target_list3 = lag_cust_dict3.get(cust_id, [0]*22)
    x_vars_list.append(x_vars + prev_target_list + lag_target_list1+lag_target_list2 + lag_target_list3)
elif row['fecha_dato'] == '2015-05-28':
    prev_target_list = cust_dict.get(cust_id, [0]*22)
    lag_target_list1 = lag_cust_dict1.get(cust_id, [0]*22)
    lag_target_list2 = lag_cust_dict2.get(cust_id, [0]*22)
    lag_target_list3 = lag_cust_dict3.get(cust_id, [0]*22)
    target_list = Process_products(row)
    new_products = [max(x1 - x2,0) for (x1, x2) in zip(target_list, prev_target_list)]
    if sum(new_products) > 0:
        for ind, prod in enumerate(new_products):
            if prod>0:
                assert len(prev_target_list) == 22
                x_vars_list.append(x_vars+prev_target_list+lag_target_list1+lag_target_list2+lag_target_list3)
                y_vars_list.append(ind)

```

- Nếu ngày là **2016-05-28**, lấy trạng thái sản phẩm trong các tháng trước.
 - i. Lấy danh sách **sản phẩm mà khách hàng sở hữu trong các tháng trước** từ các từ điển cust_dict và lag_cust_dict.
 1. cust_dict: Lưu trạng thái sản phẩm của khách hàng tại thời điểm một tháng trước ngày 2016-05-28.
 2. lag_cust_dict1: Lưu trạng thái sản phẩm của khách hàng tại thời điểm hai tháng trước ngày 2016-05-28.
 3. lag_cust_dict2: Lưu trạng thái sản phẩm của khách hàng tại thời điểm ba tháng trước ngày 2016-05-28.
 4. lag_cust_dict3: Lưu trạng thái sản phẩm của khách hàng tại thời điểm bốn tháng trước ngày 2016-05-28.
 - ii. Nếu khách hàng không có dữ liệu trong từ điển, mặc định là danh sách [0]*22 (22 sản phẩm, tất cả đều chưa sở hữu).
- **Lưu thông tin đặc trưng (x_vars_list)**, gồm:
 - i. Thông tin khách hàng (x_vars).
 - ii. Trạng thái sản phẩm của họ trong **tháng trước** (prev_target_list, lag_target_list1, lag_target_list2, lag_target_list3).
- Nếu ngày là **2015-05-28**, tính danh sách sản phẩm mới bằng cách so sánh với tháng trước.
- Tạo danh sách new_products là danh sách chứa số lượng sản phẩm mới được mua cho mỗi sản phẩm, với giá trị không âm.

- i. **zip(target_list, prev_target_list)**: Kết hợp từng cặp phần tử tương ứng từ target_list (danh sách mục tiêu hiện tại) và prev_target_list (danh sách mục tiêu của tháng trước).
 - ii. **x1 - x2**: Tính chênh lệch số lượng sản phẩm giữa tháng hiện tại (x1) và tháng trước (x2).
 - iii. **max(x1 - x2, 0)**: Đảm bảo rằng giá trị chênh lệch không âm. Nếu chênh lệch âm (tức là số lượng sản phẩm giảm), giá trị sẽ được đặt là 0.
- Xác định xem tổng số sản phẩm mới được mua có lớn hơn 0 hay không.
 - Đảm bảo rằng danh sách prev_target_list có đúng 22 phần tử.
 - Cuối cùng, Thêm dữ liệu đặc trưng và nhãn tương ứng vào các danh sách để huấn luyện mô hình.

- **Trả về danh sách đặc trưng và nhãn dự đoán:**

```
return x_vars_list, y_vars_list, cust_dict, lag_cust_dict1, lag_cust_dict2, lag_cust_dict3
```

- x_vars_list, y_vars_list: Dữ liệu huấn luyện cho mô hình.
- cust_dict, lag_cust_dict1, lag_cust_dict2, lag_cust_dict3: Cập nhật trạng thái sản phẩm cho các tháng tiếp theo.

4. Mô tả các biến sử dụng trong mô hình

Danh sách đặc trưng được chọn:

Đặc trưng phân loại (Categorical Features):

- **sexo**: Giới tính
- **ind_nuevo**: Khách hàng mới?
- **segmento**: Phân khúc khách hàng
- **indext**: Chỉ số người nước ngoài
- **indresi**: Chỉ số cư trú
- **indrel**: Khách hàng chính thức vào đầu tháng nhưng không còn vào cuối tháng
- **indrel_1mes**: Loại khách hàng vào đầu tháng
- **indfall**: Chỉ số khách hàng đã mất
- **tiprel_1mes**: Loại quan hệ khách hàng vào đầu tháng
- **ind_actividad_cliente**: Khách hàng có hoạt động không?
- **tipodom**: Loại địa chỉ. 1: Địa chỉ chính
- **pais_residencia**: Quốc gia cư trú của khách hàng
- **canal_entrada**: Kênh khách hàng sử dụng để tham gia dịch vụ

Đặc trưng số (Numerical Features):

- **age**: Tuổi (tính theo năm)
- **antiguedad**: Thâm niên (tính theo tháng)
- **renta**: Thu nhập gộp theo tỉnh/thành phố

Đặc trưng đã được xử lý (Engineered Features):

- **ownership**: Đặc trưng nhị phân cho biết khách hàng đã sở hữu sản phẩm hay chưa trong vòng 1-5 tháng trước đó ($5 \times 22 =$ tổng cộng 110 đặc trưng)
- **added products**: Đặc trưng nhị phân cho biết khách hàng đã thêm sản phẩm trong tháng gần nhất hay chưa.

IV. Model Training and Evaluation

1. Lựa chọn mô hình - XGBoost

Hệ thống gợi ý của chúng tôi sử dụng mô hình cây phân loại tăng cường theo độ dốc (gradient boosted classification trees), với **XGBoost** là công cụ chính. XGBoost là một thư viện học máy mạnh mẽ, có hiệu suất cao, hỗ trợ tính toán song song và cung cấp điều chuẩn L1/L2 giúp cải thiện độ chính xác của mô hình.

- Gradient Boosting – Cách hoạt động

Gradient boosting xây dựng nhiều mô hình học yếu (weak learners), thường là cây quyết định, theo cách mỗi mô hình mới tập trung sửa lỗi của mô hình trước đó. Bằng cách điều chỉnh trọng số của dữ liệu dựa trên sai số, mô hình cuối cùng là sự kết hợp của nhiều mô hình nhỏ, giúp cải thiện độ chính xác.

- Ứng dụng trong phân loại đa lớp - Multiple Classification

Mô hình XGBoost được huấn luyện để dự đoán sản phẩm mà khách hàng sẽ mua thêm, sử dụng **objective = "multi:softprob"** để tính toán xác suất cho tất cả sản phẩm cùng lúc. Khi khách hàng mua nhiều sản phẩm, một sản phẩm ngẫu nhiên được chọn làm biến mục tiêu để đảm bảo tính nhất quán của dữ liệu huấn luyện.

2. Tham số mô hình

objective = 'multi:softprob' sẽ trả về một vector chứa tất cả các xác suất thay vì chỉ trả về giá trị có xác suất cao nhất như 'multi:softmax'. Chúng ta cần toàn bộ xác suất này để xếp hạng các sản phẩm và đề xuất sản phẩm phù hợp cho khách hàng.

- Các tham số quan trọng ảnh hưởng đến hiệu suất mô hình và giúp giảm overfitting:

- **eta** (mặc định = 0.3)
 - Tương tự như learning rate trong GBM.
 - Giúp mô hình ổn định hơn bằng cách giảm dần trọng số trong từng bước cập nhật.
 - Giá trị thường được sử dụng: **0.01 - 0.2**.
- **min_child_weight** (mặc định = 1)

- Xác định tổng trọng số tối thiểu của tất cả các quan sát cần có trong một node con.
- Kiểm soát overfitting: giá trị cao hơn giúp mô hình tránh học các quan hệ quá đặc trưng từ mẫu cụ thể.
- Giá trị quá cao có thể dẫn đến underfitting.
- **max_depth (mặc định = 6)**
 - Độ sâu tối đa của cây quyết định.
 - Kiểm soát overfitting: độ sâu lớn hơn giúp mô hình học chi tiết hơn nhưng có nguy cơ bị overfitting.
 - Giá trị thường được sử dụng: **3 - 10**.
- **subsample (mặc định = 1)**
 - Tỷ lệ quan sát được lấy mẫu ngẫu nhiên cho mỗi cây.
 - Giá trị thấp giúp mô hình bảo thủ hơn, tránh overfitting nhưng nếu quá nhỏ có thể gây underfitting.
 - Giá trị thường được sử dụng: **0.5 - 1**.
- **colsample_bytree (mặc định = 1)**
 - Tỷ lệ số lượng cột (đặc trưng) được chọn ngẫu nhiên cho mỗi cây.
 - Giá trị thường được sử dụng: **0.5 - 1**.

- Tối ưu hóa tham số mô hình - GridSearchCV

GridSearchCV là một phương pháp tìm kiếm tham số tối ưu bằng cách thử nghiệm nhiều tổ hợp khác nhau và đánh giá hiệu suất của mô hình với từng tổ hợp. Trong bài toán này, chúng tôi sử dụng GridSearchCV để tối ưu các tham số quan trọng của mô hình XGBoost, nhằm **đạt được giá trị MAP cao nhất**.

Quy trình thực hiện **GridSearchCV**:

- **Bước 1:** Xác định tập tham số cần tinh chỉnh, bao gồm **eta**, **max_depth**, **subsample**, **colsample_bytree**, **min_child_weight**.
- **Bước 2:** Khởi tạo mô hình XGBoost với các thiết lập mặc định.
- **Bước 3:** Chạy GridSearchCV với bộ tham số đã xác định, sử dụng **Mean Average Precision (MAP)** làm chỉ số đánh giá chính.
- **Bước 4:** Thực hiện **Cross-Validation (CV)** với phương pháp **StratifiedKFold** để đảm bảo độ tổng quát của mô hình.
- **Bước 5:** Chọn bộ tham số tốt nhất và huấn luyện mô hình cuối cùng với bộ tham số này.

Sau khi chạy GridSearchCV, chúng tôi chọn ra bộ tham số tối ưu nhất và sử dụng nó để huấn luyện mô hình cuối cùng nhằm tối đa hóa hiệu suất gợi ý sản phẩm.

3. Dự đoán

Sau khi tìm ra tham số tối ưu và huấn luyện mô hình XGBoost, chúng tôi tiến hành dự đoán các sản phẩm mà khách hàng có khả năng mua tiếp theo. Quá trình dự đoán được thực hiện theo các bước sau:

- Dự đoán xác suất

Mô hình XGBoost được sử dụng để dự đoán xác suất của từng sản phẩm cho mỗi khách hàng trong tập kiểm tra (test set). Cụ thể:

- Dự đoán xác suất của từng sản phẩm cho từng khách hàng.
- Kết quả trả về là một ma trận, trong đó mỗi hàng tương ứng với một khách hàng, và mỗi cột là xác suất của một sản phẩm.

- Lưu danh sách sản phẩm được đề xuất theo xác suất giảm dần

- Xếp hạng các sản phẩm theo xác suất dự đoán từ cao đến thấp.
- Kết quả cuối cùng được lưu trong một DataFrame, bao gồm **ID khách hàng (ncodpers)** và **danh sách sản phẩm được đề xuất (added_products)**.
- Các sản phẩm được đề xuất sẽ ngăn cách nhau bởi một dấu cách.

Ví dụ 5 dòng đầu của dự đoán:

	ncodpers	added_products
0	657640	ind_cco_fin_ult1 ind_dela_fin_ult1 ind_tjcr_fi...
1	657788	ind_recibo_ult1 ind_tjcr_fin_ult1 ind_dela_fin...
2	657795	ind_recibo_ult1 ind_tjcr_fin_ult1 ind_dela_fin...
3	657790	ind_tjcr_fin_ult1 ind_reca_fin_ult1 ind_cco_fi...
4	657794	ind_recibo_ult1 ind_tjcr_fin_ult1 ind_fond_fin...

4. Đánh giá

Để đánh giá hiệu suất của mô hình đề xuất sản phẩm, chúng tôi sử dụng chỉ số chính là **Mean Average Precision (MAP)** theo yêu cầu của bài toán. Ngoài ra, để

có đánh giá toàn diện hơn, chúng tôi bổ sung thêm hai chỉ số **Precision@k** và **Recall@k** nhằm đo lường mức độ chính xác và độ bao phủ của mô hình gợi ý.

4.1. Mean Average Precision (MAP)

MAP (Mean Average Precision) là một chỉ số đánh giá phổ biến trong các bài toán recommendation. Chỉ số này đo lường mức độ chính xác của toàn bộ danh sách sản phẩm được đề xuất cho khách hàng, có tính đến thứ tự của các sản phẩm trong danh sách dự đoán. Công thức của MAP như sau:

$$MAP = \frac{1}{N} \sum_{i=1}^N AP_i$$

Trong đó:

- N là tổng số khách hàng.
- AP_i là **Average Precision (AP_i)** của khách hàng thứ i, được tính như sau:

$$AP = \frac{1}{m} \sum_{k=1}^m P(k) \cdot \text{rel}(k)$$

Với:

- m là số lượng sản phẩm được đề xuất.
- $P(k)$ là độ chính xác (Precision) tại vị trí k.
- $\text{rel}(k)$ là giá trị nhị phân (1 nếu sản phẩm đúng, 0 nếu sai).

Trong bài toán này, chúng tôi tính toán thêm cả **MAP@5**, tức là chỉ xét **top-5 sản phẩm** được mô hình đề xuất. Công thức tính MAP@5 tương tự MAP nhưng chỉ xét $k = 5$.

4.2. Precision

Precision đo lường **tỷ lệ sản phẩm dự đoán đúng** so với tổng số sản phẩm thực sự được mua bởi khách hàng. Công thức như sau:

$$\text{Precision} = \frac{\text{Số sản phẩm dự đoán đúng}}{\text{Tổng số sản phẩm dự đoán}}$$

Precision giúp đánh giá mức độ chính xác tổng thể của mô hình mà không giới hạn số lượng sản phẩm gợi ý.

Trong bài toán này, chúng tôi tính toán **Precision@5**, tức là chỉ xét **top-5 sản phẩm** được mô hình đề xuất. Công thức tính Precision@5 tương tự nhưng chỉ xét $k = 5$.

4.3. Recall

Recall đo lường **tỷ lệ sản phẩm thực tế mà khách hàng đã mua được mô hình dự đoán đúng**. Công thức như sau:

$$\text{Recall} = \frac{\text{Số sản phẩm dự đoán đúng}}{\text{Tổng số sản phẩm thực tế khách hàng mua}}$$

Recall phản ánh khả năng của mô hình trong việc bao quát toàn bộ nhu cầu thực tế của khách hàng.

Tương tự, chúng tôi cũng tính **Recall@5**, tức là chỉ xét **top-5 sản phẩm** trong danh sách gợi ý.

4.4. Kết quả đánh giá

Chúng tôi thực hiện đánh giá mô hình trên tập kiểm tra (test set) và thu được các kết quả sau:

Chỉ số	Giá trị
MAP	0.0277
MAP@5	0.0275
Precision@5	0.0077
Recall@5	0.0302

Phân tích kết quả:

Các điểm số đánh giá cho thấy hiệu suất của mô hình còn thấp. Nguyên nhân chính đến từ sự **mất cân bằng dữ liệu**:

- Dữ liệu dự đoán bao gồm hơn **900 nghìn khách hàng** nhưng chỉ có khoảng **29 nghìn khách hàng** thực sự mua thêm sản phẩm mới.
- Điều này có nghĩa là chỉ có khoảng **3%** tổng số khách hàng thực sự có giao dịch, khiến việc dự đoán trở nên khó khăn.

Đánh giá trên tập khách hàng thực sự mua thêm:

Nhằm đánh giá chính xác hơn, chúng tôi chỉ tính toán các chỉ số trên **29 nghìn khách hàng** đã thực sự mua thêm sản phẩm:

Chỉ số	Giá trị
MAP	0.9541
MAP@5	0.9010
Precision@5	0.2418
Recall@5	0.9513

Nhận xét:

- Khi chỉ xét trên nhóm khách hàng thực sự có giao dịch, **MAP@5 đạt 0.9010**, chứng tỏ rằng mô hình có độ chính xác cao trong việc gợi ý các sản phẩm phù hợp.
- **Precision@5 = 0.2418** cho thấy rằng trong top-5 sản phẩm đề xuất, có khoảng **24.18% sản phẩm là chính xác**.
- **Recall@5 = 0.9513**, tức là mô hình **đã bao phủ tới 95.13% sản phẩm khách hàng thực sự mua**.

Mô hình đạt hiệu suất rất cao khi đánh giá trên nhóm khách hàng có giao dịch, chứng tỏ thuật toán hoạt động tốt trong việc dự đoán nhóm khách hàng có nhu cầu thực sự.

Lý do chọn $k = 5$

Trong bài toán này, chúng tôi chọn **$k = 5$** (tức là chỉ đề xuất tối đa 5 sản phẩm cho mỗi khách hàng) dựa trên các lý do sau:

1. **Tránh quá tải thông tin:** Nếu đề xuất quá nhiều sản phẩm, khách hàng có thể bị quá tải và khó đưa ra quyết định.
2. **Đặc thù ngành ngân hàng:** Khác với bán lẻ, trong lĩnh vực ngân hàng, khách hàng thường không mở nhiều sản phẩm tài chính mới cùng một lúc. Đề xuất **5 sản phẩm** giúp tăng khả năng chọn đúng mà không gây phiền phức cho khách hàng.

V. Tối ưu code

Khi làm việc với dữ liệu lớn, tối ưu hóa code không chỉ giúp tiết kiệm tài nguyên mà còn nâng cao tốc độ xử lý. Đặc biệt, khi sử dụng **Google Colab** – nơi RAM bị giới hạn, việc quản lý bộ nhớ hiệu quả là điều bắt buộc. Vì vậy, nhóm chúng tôi đã áp dụng các chiến lược tối ưu giúp xử lý dữ liệu nhanh hơn, tiết kiệm RAM và tránh tình trạng "Colab bị treo".

1. Tối ưu hóa bằng hàm (def)

- Tái sử dụng code: Giảm lặp lại, dễ bảo trì.
- Cải thiện hiệu suất: Hạn chế việc gọi lại những đoạn code không cần thiết.
- Giữ code gọn gàng, dễ đọc

2. Tải xuống dataset đã được chuẩn hóa và làm sạch

Sau khi làm sạch dữ liệu, nhóm chúng tôi tải xuống dataset đã được chuẩn hóa và làm sạch. Điều này giúp:

- **Linh hoạt trong việc sử dụng:** Dataset đã được xử lý có thể dùng ngay mà không cần thực hiện lại các bước tiền xử lý.
- **Tránh tốn thời gian trước khi phân tích chuyên sâu:** Không phải xử lý lại dữ liệu mỗi lần chạy model.
- **Tiết kiệm tài nguyên:** Giảm tải bộ nhớ và tránh làm Colab bị treo do dữ liệu quá lớn.

3. Dùng `csv.DictReader` để đọc từng dòng, tiết kiệm RAM

Đối với dữ liệu đề bài được cung cấp có độ lớn khoảng 2.3 GB, nhóm chúng tôi đã sử dụng `csv.DictReader` để đọc file. `DictReader` đọc từng dòng của tệp CSV và trả về mỗi dòng dưới dạng một từ điển (dict), với các cột là key và giá trị tương ứng. Điều này giúp tiết kiệm RAM so với việc đọc toàn bộ file vào bộ nhớ cùng một lúc:

- **Tiết kiệm bộ nhớ:** Thay vì đọc toàn bộ file vào bộ nhớ (như `pandas.read_csv` thông thường), `DictReader` xử lý từng dòng một cách tuần tự, giúp giảm tải RAM.
- **Dễ dàng thao tác dữ liệu:** Mỗi dòng được lưu dưới dạng một dictionary, giúp việc truy xuất dữ liệu theo cột trở nên thuận tiện.
- **Tăng tốc độ xử lý cho tập dữ liệu lớn:** Với file CSV có kích thước lớn, việc đọc từng dòng một giúp tránh lỗi `MemoryError` khi xử lý.

VI. CONCLUSION & RECOMMENDATIONS:

1. Conclusion

1.1. EDA

Dựa vào thông tin khi khai phá dữ liệu, ta có thể rút ra thông tin về

A. Đối tượng khách hàng của ngân hàng:

- 99% khách hàng là người ngoài ngân hàng, tập trung chủ yếu tại Tây Ban Nha (4,62 triệu).
- Độ tuổi phổ biến: Từ 23-25 và 40-45 tuổi, cho thấy hai nhóm khách hàng quan trọng.
- Giới tính cân bằng nhưng nữ chiếm ưu thế nhẹ (2,5 triệu so với 2,1 triệu nam).
- Thâm niên khách hàng ngắn hạn: Đa số gắn bó dưới 4 năm, nhưng có một nhóm khách hàng lâu năm (~150 tháng).

B. Hành vi sử dụng sản phẩm tài chính:

- Nam: Ưu tiên tài khoản điện tử, tài khoản hiện tại và ghi nợ tự động.
- Nữ: Ưu tiên tài khoản hiện tại, lương hưu và có xu hướng lập kế hoạch tài chính dài hạn.
- Thu nhập càng cao → Càng sử dụng nhiều sản phẩm: Nhóm thu nhập thấp chỉ dùng tài khoản cơ bản, trong khi nhóm thu nhập cao tham gia đầu tư, tín dụng và bảo hiểm dài hạn.
- Khách hàng càng lâu năm → Sử dụng càng nhiều sản phẩm, cho thấy giá trị vòng đời khách hàng (LTV) cao với những người trung thành.

C. Kênh thu hút khách hàng chính:

- Ba kênh quan trọng nhất: KHE (1,26 triệu), KAT (1,03 triệu) và KFC (1,00 triệu).
- Madrid là trung tâm khách hàng lớn nhất (1,48 triệu), tiếp theo là Barcelona (440K) và Valencia (238K).

D. Xu hướng tăng trưởng & cơ hội kinh doanh:

- Số lượng sản phẩm bán ra tăng mạnh vào tháng 2 nhưng giảm dần sau đó, cho thấy sự không ổn định trong chu kỳ mua hàng.
- Tháng 5 có dấu hiệu phục hồi, chứng tỏ có thể tận dụng để thúc đẩy tăng trưởng.

1.2. Mô hình dự đoán

Trong bài toán gợi ý sản phẩm ngân hàng, chúng tôi đã sử dụng mô hình **XGBoost** trên tập dữ liệu hơn **900 nghìn khách hàng**, với chỉ **hơn 3% khách hàng thực sự mua sản phẩm mới** trong tháng 5 năm 2016.

Tiền xử lý dữ liệu – Yếu tố then chốt

Chúng tôi đã thực hiện **mã hóa dữ liệu danh mục, chuẩn hóa đặc trưng số**, và **xây dựng đặc trưng lịch sử giao dịch** để cung cấp thông tin đầy đủ cho mô hình. Việc **lọc dữ liệu không hợp lệ và tối ưu hóa biến đầu vào** giúp cải thiện hiệu suất dự đoán.

Kết quả và đánh giá mô hình

Mô hình XGBoost đã chứng minh hiệu quả cao trong việc gợi ý sản phẩm cho khách hàng. Đặc biệt trong nhóm khách hàng thực sự sử dụng thêm sản phẩm từ tháng 4 đến tháng 5, kết quả **MAP@5** đạt **0.9010** và **Recall@5** lên tới **95.13%**, cho thấy khả năng gợi ý chính xác các sản phẩm khách hàng quan tâm. Điều này chứng tỏ mô hình có tiềm năng hỗ trợ tốt cho việc cá nhân hóa trải nghiệm khách hàng trong ngành ngân hàng.

Tuy nhiên, hiệu suất trên toàn bộ tập dữ liệu vẫn chưa cao do sự mất cân bằng giữa khách hàng có và không có giao dịch. Để cải thiện, cần tiếp tục tối ưu hóa mô hình bằng các phương pháp xử lý dữ liệu, thử nghiệm các thuật toán bổ sung và tinh chỉnh chiến lược đề xuất sản phẩm.

Nhìn chung, mô hình hiện tại đã đạt được những kết quả ấn tượng trong nhóm khách hàng mục tiêu và có thể tiếp tục cải thiện để đạt hiệu suất tốt hơn trên quy mô lớn.

2. Recommendations

A. Chiến lược phát triển khách hàng

- Tập dụng **nhóm khách hàng chính** (23-25 và 40-45 tuổi) bằng các chương trình ưu đãi phù hợp với từng độ tuổi.
- Tăng cường chăm sóc **khách hàng lâu năm** bằng các ưu đãi đặc biệt, khuyến khích họ sử dụng thêm sản phẩm tài chính khác.
- Tập trung giữ chân **khách hàng nữ**, vì họ có xu hướng lập kế hoạch tài chính dài hạn → Có thể tạo các gói dịch vụ tiết kiệm, lương hưu hoặc bảo hiểm phù hợp.

B. Tối ưu hóa kênh thu hút khách hàng

- Duy trì và mở rộng kênh KHE, KAT, KFC vì đây là những **kênh hiệu quả nhất**.
- Đẩy mạnh chiến lược tiếp cận tại các **thành phố lớn** như Madrid, Barcelona và Valencia.

C. Cải thiện chiến lược bán hàng & giữ chân khách hàng

- Cải thiện chương trình ưu đãi theo mùa để hạn chế sự sụt giảm sản phẩm bán ra sau các **tháng cao điểm** (như tháng 2).
- Tăng cường **chiến lược bán chéo** (cross-sell) cho khách hàng trung thành, đặc biệt là nhóm có thâm niên cao, để tăng số lượng sản phẩm họ sử dụng.
- Đẩy mạnh phân khúc khách hàng **thu nhập cao** với các sản phẩm đầu tư, bảo hiểm và tín dụng cao cấp hơn.

D. Sử dụng mô hình dự đoán để đưa ra gợi ý sản phẩm cho từng khách hàng

- Hệ thống có tiềm năng hỗ trợ **cá nhân hóa dịch vụ ngân hàng**, tối ưu chiến dịch tiếp thị.